

Lie Detection via Micro Expression

Hena Cho
hena0914@korea.ac.kr
Korea University
Seoul, South Korea

Wooseok Choi
woosukqw@korea.ac.kr
Korea University
Seoul, South Korea

Jihyeon Yoon
cse21jh@korea.ac.kr
Korea University
Seoul, South Korea

Junha Kim
jjun0403@korea.ac.kr
Korea University
Seoul, South Korea

Yoonheon Ro
yoonblue9@korea.ac.kr
Korea University
Seoul, South Korea

1 Introduction

미세 감정 표현은 아주 짧은 시간 동안 드러나는 감정 표현으로, 다른 사람들에게 의도적으로 자신의 감정을 숨기려 할 때에도 제어하기 어렵거나 할 수 없는 표현이다. 이에 따라 미세 감정 표현은 그 사람의 숨기거나 억누를 수 없는, 특정 순간의 진짜 생각과 태도를 반영할 수 있다. 일반적인 감정 표현을 인식하는 FER(Facial Expression Recognition) 분야는 많은 연구가 이루어지고 있지만, 그에 반해 미세 감정 표현을 이용한 연구는 미비하게 이루어지고 있다. 이러한 상황에 의거하여 최근 사람의 얼굴에서 드러나는 미세한 표정 변화, 특히 micro-expression과 facial action unit(AU) 정보를 활용한 lie detection 연구를 진행하고자 한다. 이러한 접근은 얼굴의 무의식적 반응을 기반으로 하여 보다 정밀한 분석을 가능하게 한다는 장점이 있다.

본 팀 프로젝트에서는 영상 데이터 기반 lie detection system 전 과정의 파이프라인을 설계하고 자동화 및 구현하였다. 먼저 주어진 영상 데이터를 프레임 단위로 잘라 이미지 파일로 저장한다. 이미지로 변환된 데이터로부터 onset frame과 apex frame을 선택한 뒤, apex frame으로부터는 AU 정보를 추가로 추출한다. 그리고 선정된 두 프레임 이미지를 input data로 사용하여, facial feature 및 vertical feature를 추출한다. 이렇게 추출한 세 종류의 features를 사용한 binary classification을 통해 lie detection을 수행한다. 이 과정은 Figure 1의 그림의 형태로 작동한다.

모델의 성능은 classification의 결과를 confusion matrix와 ROC curve를 통해 분석하여 평가하였다. 완성된 모델은 기초적인 모델에 비해 정확도를 측정하기 위한 모든 지표에서 큰 폭의 향상을 보였으며 비교 모델 중 가장 뛰어난 성능 개선 효과를 보였다.

본 프로젝트를 통해 lie detection에 적합한 facial feature를 확보할 수 있었다. 이를 통해 향후 다양한 영상 기반 행동 거짓말 탐지에 활용할 수 있는 기반을 마련하였다.

2 Background

2.1 Micro-expression

감정은 편도체에서 유래하여 발생하는 무의식적인 생물 심리사회학적 반응이다. 그중에서도 미세 감정 표현은 아주 짧은 시간, 전형적으로 0.5초 미만의 시간 동안 드러나는 감정 표현으로, 일반적인 표정과 달리 미세 감정 표현을 숨기는 것은 매우 어렵거나 사실상 불가능하다. 이는 아주 짧은 시간 동안, 작은 변화로 일어나는 반응으로 사람이 직접 포착하는 것은 어렵지만, 고속 카메라나 영상을 느리게 하여 재생하는 방식 등으로 포착할 수 있다. 미세 감정 표현의 종류에는 놀람, 공포, 충격, 슬픔, 분노, 행복, 경멸이 주가 되며, 1990년대에 폴 에크만이 확장한 감정 목록까지 포함하면 즐거움, 당혹감, 불안, 죄책감, 자부심, 안도감, 만족, 즐거움, 수치심이 있다.




Figure 1: Diagram of our model.

2.2 Action Unit

Action Unit은 얼굴 근육을 기반으로 얼굴 표정을 분석하기 위해 사용되는 얼굴 근육의 동작 단위이다. 눈썹의 움직임, 입술의 움직임, 턱의 움직임 등 각각의 움직임 단위를 coding하였으며, 이를 통해 특정 감정에서의 Action Unit code를 정형화 할 수 있다. 예를 들어, 공포는 일반적으로 Inner Brow Raiser(AU1), Outer Brow Raiser(AU2), Brow Lowerer(AU4), Upper Lid Raiser(AU5), Lid Tightener(AU7), Lip Stretcher(AU20), Jaw Drop(AU26)를 사용하여 표현할 수 있으며, 각 AU의 intensity에 따라 감정의 크기가 표현된다. 본 연구에서는 AU1, AU2, AU4, AU5, AU6, AU7, AU9, AU10, AU12, AU14, AU15, AU17, AU20, AU23, AU24, AU25, AU26을 추출하여 사용하였다. [1-6]

3 Preprocessing

우선 데이터 가공에 앞서 참/거짓이 라벨링된 영상 혹은 이미지 데이터셋을 탐색하였다. 선행 연구에서 사용한 데이터셋은 크게 4가지로, Real-life Trial Dataset, Silesian Deception Dataset, Bag-of-Lies, CogniModal-D이며, 추가적으로 Kaggle에서 찾은 Lie Detection using Micro Expression Dataset이 있다. [7-11] Real-life Trial Dataset은 실제 법정에서 촬영된 영상으로, 위증 여부에 따라 참/거짓이 라벨링되어 있다. 이는 Lie detection 분야에서 전통적으로 많이 사용하던 데이터셋이다. Silesian Deception Dataset은 실험실 환경에서 촬영된 데이터셋이고, Bag-of-Lies, CogniModal-D는 영상 데이터와 함께 시선처리, EEG 등의 multimodal label이 담긴 데이터셋이다.

Bag-of-Lies와 Silesian Deception Dataset의 데이터 저작자에게 데이터셋을 요청했으나 동의를 얻지 못했고, 마지막 CogniModal-D는 2025년 3월에 나온 논문에서 사용된 데이터셋이므로 아직 이용이 불가능했다. 결과적으로 이번 팀 프로젝트에서는 Real-Life Trial Dataset과 Kaggle의 Lie Detection using Micro Expression

Dataset을 사용하였다. Real-Life Trial Dataset에서 총 101개의 데이터, Lie Detection using Micro Expression Dataset에서 96개의 데이터를 사용하여 총 197개의 데이터를 사용해 학습과 테스트를 진행하였다.

Real-Life Trial Dataset은 영상 데이터이고, Lie Detection using Micro Expression Dataset은 영상을 프레임 단위로 자른 형태였다. Apex와 Onset Frame을 뽑기 위해서는 프레임 단위로 나눈 연속된 이미지 형태가 사용하기 편하기 때문에 영상 데이터는 모두 프레임 단위로 나뉜 이미지 형태로 사용했다.

3.1 Onset/Apex Frame Extraction

영상 데이터와 같은 연속적인 데이터를 처리할 때, 크게 두 가지 방식이 있다. 첫 번째는 영상 데이터를 시간 축 데이터를 함께 사용하는 3D-CNN과 같은 방식이고, 다른 하나는 영상 데이터를 압축하는 몇 개의 프레임을 뽑아내서 시간 축 데이터를 제외한 기존의 2D 방식의 모델을 사용하는 방식이다. 최초에는 3D-CNN 방식을 고려하였으나, Micro Expression을 처리하기 위해서는 깊은 모델이 필요할 텐데 거기에 시간을 고려하면 2D 방식에 비해 8배 이상의 GPU 메모리가 필요하므로 우리가 가진 32GB의 VRAM으로는 충분하지 않을 것으로 예상되었다. 따라서 두 번째 방식인, 영상 데이터를 대표하는 프레임을 뽑아내는 방식을 사용하기로 결정했다. [12]

우리가 사용한 방식은 영상에서 Facial Expression을 처리할 때 가장 많이 사용하는 Onset/Apex Frame 방식이다. Onset 프레임은 영상이 시작하는 첫 프레임, Apex 프레임은 가장 변화가 큰 프레임을 의미한다. 영상을 시간에 따라 변화하는 이미지 관점으로 봤을 때, 극값의 개념처럼 일종의 extreme 프레임인 것이다. Micro Facial Expression은 대부분의 프레임에서는 아주 작은 변화만을 보이기 때문에, 그 중에서 가장 변화가 큰 프레임을 사용하면 좋은 결과를 얻을 것이라고 예상했다.

프레임 간의 변화는 두 가지 요소에 가중치를 곱하여 계산된 motion score를 사용해 측정하였다. 첫째, Farneback 알고리즘을 활용하여 두 프레임의 픽셀 움직임을 계산해 평균값을 구한다(optical flow). [?] 둘째, MediaPipe 라이브러리 중 Face Mesh를 이용하여 눈, 코, 입 등의 얼굴 랜드마크를 추출하고 유클리드 거리값을 이용하여 위치 변화량을 구한다(landmark displacement). [13] [14] 이 두 값을 각각 0.7:0.3 비율로 가중합하여 최종 motion score를 결정하였다. 영상 데이터를 이미지로 압축해서 사용하는 것인 만큼 연속성을 고려하는 것이 중요한데, landmark displacement보다 optical flow가 표정의 연속성을 더 잘 반영하기 때문에 위와 같이 optical flow에 더 가중치를 줬다.

계산된 motion score를 기반으로 수치가 가장 큰 프레임을 apex frame으로 지정하였으며, 임계치 1.5 이상의 수치를 보이는 프레임을 onset frame으로 지정하였다. 최종적으로 추출된 onset/apex frame은 각각 Facial Feature Extraction과 Temporal Motion Feature Extraction의 input값으로, 추가로 apex frame은 단독적으로 AU Extraction을 위한 input값으로 이용된다.

3.2 AU Extraction

영상 클립으로부터 추출된 apex frame 이미지에서 Facial Action Unit(AU)을 정량적으로 추출하는 과정을 수행한다. AU란 얼굴 근육의 움직임을 기반으로 얼굴 표정을 분석하기 위해 사용되는 얼굴 근육 동작 단위로, AU Extraction을 통해 특정 근육 동작 움직임의 presence와 intensity를 측정할 수 있다.

AU 추출에는 딥러닝 기반의 얼굴 분석 도구인 LibreFace를 활용하였다. LibreFace는 사전 학습된 모델을 기반으로 사람의 얼굴을 인식하고, 내부적으로 정렬한 다음 CNN 기반 AU 예측 딥러닝 모델을 통해 17개의 AU Unit에 대한 presence와 intensity 값을 예측한다.

끝으로, 추출된 AU 정보에 대한 통일성 유지를 위해 후처리를 진행하였다. LibreFace에서 감지할 수 있는 AU 목록 중에서 누락된 AU attribute는 0으로 채우고, presence 및 intensity에 대한 정보만 남겨 정렬하여 총 29-dimension AU feature 벡터를 담은 csv 파일을 생성하였다. 본 과정을 통해 apex frame 기반의 AU 추출과 전처리 절차를 자동화하고, 모델 학습에 필요한 정제된 AU 데이터를 효과적으로 확보하였다. [15]

4 Method

4.1 Facial Feature Extraction

Micro expression의 경우 얼굴의 미세한 특징들을 통해서 추출해야 하며, CNN에서 이를 추출하기 위해서는 깊은 네트워크의 구성과 미세한 특징들의 보존이 필요하다. ResNet-50의 경우 Bottleneck Block, Residual Block, Skip Connection을 사용한다는 특징이 있는데, Bottleneck Block은 Block 중간에 채널 수를 줄이는 과정이 추가되어 중요한 특성은 유지하며 계산 효율성을 늘릴 수 있다. 이를 통해 비교적 적은 연산을 통해 깊은 네트워크의 구성이 가능하다.

Residual Block(잔차 블록)을 통해서 네트워크 간 입력과 출력 간의 차이에 집중하는데, 때문에 레이어에서 이미 추출된 특징의 경우 다음 Residual Block에서 해당 특징을 일정 부분 유지하여 미세한 특징 탐색에 집중할 수 있다.

Skip Connection을 통해서 입력 정보의 일부를 몇 개의 레이어를 건너뛰어 다음 레이어로 전달해 주는데, 이는 학습을 진행하며 미세한 특징이 손실되는 것을 막아줄 수 있다. 이러한 특징들을 통해 ResNet은 미세한 특징들을 잃지 않고 Facial Feature를 추출할 수 있다.

이러한 이유로 인해 Facial Feature를 추출하기 위해 ResNet-50 모델을 사용했다. 해당 모델에선 input으로 Onset/Apex Frame 각각을 RGB 3개의 채널로 변환한 (3,224,224) 크기의 tensor를 사용하며, output으로 (196,14,14) 크기의 결과물이 나온다. 이후 Onset/Apex Frame의 두 결과물을 element-wise addition 하여 최종 결과물을 추출한다.

4.2 Temporal Motion Feature Extraction(TMFE)

Micro Expression의 경우 미세하지만, 다른 얼굴의 움직임보다 입꼬리, 눈썹과 같은 움직임이 비교적 크게 나타난다. 그리고 그러한 움직임의 경우 vertical한 움직임의 특징이 더욱 도드라지게 나타난다. 이러한 점 때문에 추가적으로 vertical한 움직임에 초점을 맞춰 특징을 추출하는 Method를 사용하였다.

앞선 Facial Feature의 경우 앞선 Preprocess 과정에서 추출한 Onset, Apex Frame의 특징만을 추출하는 것이기 때문에 Frame을 각각 넣어 특징을 추출한 후 최종적으로 addition하여 결과를 추출했지만, TMFE의 경우 화자가 말하며 변화하는 얼굴의 특징 변화에 초점을 맞추기 때문에 Onset, Apex Frame간의 표정 차이가 input으로 들어가야 한다. 이를 위해 Apex Frame에서 Onset Frame을 element-wise subtraction한 후, RGB 3개의 채널을 가진 (3,224,224) 크기의 tensor를 input으로 사용하였다. Element-wise subtraction을 적용하게 되면 가장 변화가 큰 Apex Frame(Extreme 프레임)과 Onset frame(기본 프레임)을 뺀 최대 변화량이 입력으로 들어가게 된다.

Temporal Motion Feature를 추출하기 위한 모델로 ResNet-18 모델을 베이스로 사용하였으며, 여기에 추가로 Continuous Vertical Attention Block(CVA Block)을 추가하였다. CVA Block의 경우 베이스 모델에서 layer별 Attention Map을 이전 layer의 Attention Map과 통합하여 추출하며, Vertical 특징 추출을 위해 Y Attention Map만 추출한다.

ResNet-18 모델의 경우 총 4개의 반복되는 Basic Block으로 구성되어 있는데, CVA Block의 경우 Basic Block의 뒤에 삽입된다. CVA Block에서 추출할 Y Attention Map은 해당 ResNet Block의 결과물을 Y Average Pooling한 것과 이전 CVA Block의 결과물을 합쳐 추출한다. 해당 Attention Map은 Layer에 영향을 끼치지 않으며, 마지막 attention map은 ResNet의 결과물과 element-wise multiplication하여 (512,14,14)크기의 최종 결과물을 추출한다. [16]

4.3 Binary Classifier

이진 분류 모델은 2개의 히든 레이어를 포함해 총 4개의 레이어를 가지는 신경망으로 구현하였다. input layer에서는 Facial feature embedding vectors, Vertical feature embedding vectors, 그리고 AU embedding vectors를 concatenate하여 $196 \times 14 \times 14 + 512 \times 14 \times 14 + 29$, 총 138,797개의 features를 입력받는다. 각 선행 레이어를 통과할 때마다 batch normalization 1d, ReLU fuction, dropout을 추가하여 정규화와 과적합 방지를 수행했다. 최종적으로 138,797 -> 1,024 -> (batch normalization 1d, ReLU, drop out) -> 512 -> (batch normalization 1d, ReLU, drop out)-> 1의 순서로 이진 분류를 수행한다.

5 Evaluation

먼저 가장 간단한 모델의 성능을 분석한 후, 각 서브 모델의 성능을 평가하기 위해 서브 모델을 하나씩 추가하며 성능을 비교하였다. 개별적으로 성능을 평가한 서브 모델은 각각 CVA Block, AU Embedding이다. 마지막으로 모든 서브 모델을 포함한 최종 모델의 성능을 평가하였다.

5.1 Datasets

사용한 데이터셋은 다음과 같다: Kaggle의 거짓말 탐지를 위한 Micro Expression 데이터셋, Real-life deception(법정 위증 데이터셋). 이 두 가지 데이터셋에서 총 170개의 데이터를 수집해 6:1:3의 비율로 나누어 각각 학습, 검증, 평가를 위해 사용하였다. 모든 데이터는 'Preprocessing'에서 사용한 방법을 통해 전처리를 진행한 후 사용하였다.

5.2 Metrics

Binary classification의 성능 평가를 위해 confusion matrix와 ROC curve를 활용하였다. 데이터의 실제 클래스(Actual class)와 우리 모델이 예측한 클래스(Predicted class)를 비교해 true positive(TP), true negative(TN), false positive(FP), false negative(FN)를 계산하였다. 계산 결과를 바탕으로 우리 모델의 예측 결과에 대한 confusion matrix를 생성하고 주요 지표인 Accuracy(정확도), Precision(정밀도), Recall(재현율), F1 score를 계산하였다. 또한 TPR(True positive rate)와 FPR(False positive rate)을 계산해 ROC curve를 생성하고 AUC score를 도출하였다. 모든 성능 지표에 대한 계산 이후에는 confusion matrix와 ROC curve를 시각화하여 분석하였다.

5.3 Result

Feature 추출에 사용되는 각 서브 모델이 성능에 미치는 영향을 분석하기 위해 총 4가지 조합으로 성능 평가를 진행하였다. 우선




Figure 2: Confusion matrix and ROC curve of Baseline (ResNet)




Figure 3: Confusion matrix and ROC curve of Baseline + CVA Block




Figure 4: Confusion matrix and ROC curve of AU Embedding + Baseline




Figure 5: Confusion matrix and ROC curve of Final model (AU Embedding + Baseline + CVA Block)

Baseline으로는 ResNet을 사용해 facial feature를 추출한 뒤 classifier를 사용해 이진 분류를 수행하는 가장 간단한 모델의 성능을 평가하였다. 이후로는 Baseline을 기준으로 각각 CVA Block과 AU Embedding을 추가한 모델의 성능을 비교하였으며 마지막으로 모든 서브 모델을 포함한 최종 모델의 성능을 평가하였다. Figure 2,

Method	Accuracy	Precision	Recall	F1 score	AUC score
Baseline(ResNet)	0.7708	0.7391	0.7727	0.7555	0.8392
Baseline + CVA Block	0.8333	0.84	0.84	0.84	0.9391
AU Embedding + Baseline	0.8125	0.8333	0.7143	0.7692	0.9083
Final model	0.8958	0.8519	0.9583	0.9020	0.9844

Table 1: Comparison of models

3, 4, 5는 각 모델의 성능을 확인하기 위한 시각화 결과이며 Table 1은 이를 비교하기 위해 정리한 표이다.

Table 1을 살펴보면 모든 지표에서 전반적으로 Baseline을 기준으로 AU Embedding + Baseline, Baseline + CVA Block, Final model의 순서로 성능이 향상되는 것을 확인할 수 있다. AU Embedding + Baseline의 경우, Baseline과 비교해 Precision에서 12.75%로 가장 큰 향상폭을 보였으나, Recall은 오히려 7.56% 감소하였다. Baseline + CVA Block은 Baseline에 비해 Accuracy와 AUC score가 각각 8.11%, 11.9% 향상되었으나, Precision, Recall, F1 score는 큰 변화가 없었다. 이에 반해 Final model은 각각 16.22%, 15.26%, 24.02%, 19.39%, 17.3%로 모든 지표에서 가장 큰 폭의 향상을 보였다. 이는 각 서브 모델의 추가가 성능 향상에 기여했으며, 이를 전부 포함한 최종 모델이 전반적으로 가장 뛰어난 성능 개선 효과를 보였음을 보여 준다.

6 Conclusion

본 팀 프로젝트에서는 facial feature extraction과 temporal motion feature extraction을 사용해 feature를 추출한 뒤 이진 분류 모델을 사용해 주어진 영상 데이터를 기반으로 거짓말을 탐지하는 연구를 진행하였다. 구체적으로는 AU Embedding, ResNet, CVA Block, Neural Network를 사용하였으며 성능 평가를 위해서는 confusion matrix와 ROC curve를 사용하였다. 결과적으로 완성된 모델은 모든 지표에서 기초적인 모델과 비교해 가장 뛰어난 성능 개선 효과를 보였다. 이를 통해 영상 기반 행동 거짓말 탐지에 활용할 수 있는 파이프라인을 설계 및 구현하였다.

A Vertical Feature in Micro Expression

Micro Expression을 판별함에 있어서 Vertical 특징이 유리하다 판단하여 Y Average Pooling을 사용한 CVA Block을 사용하였는데, Y Avg Pooling이 실제로 유의미한 결과 산출에 도움이 되었는지 여부에 대한 의문점이 존재했었다. 이에 의문점을 가지고 극단적인 예시를 확인하기 위해 Y AVG Pooling에 해당하는 부분만 X Avg Pooling으로 변경하여 training을 진행해 보았다.




Figure 6: Confusion matrix and ROC curve of X Avg Pooling

AU Embedding, ResNet, CVA Block을 모두 사용하였으나 Figure 6에서 볼 수 있듯이 오히려 Baseline과 비교해 성능이 부족하다는 결과를 확인할 수 있었다. 이를 통해 Y Avg Pooling을 사용한 CVA

Block이 micro expression 추출에 유의미한 영향을 미치고 있음을 확인할 수 있었다.

B Role

- 김준하: Feature extraction
- 노윤현: Data preprocessing, Training
- 윤지현: AU extraction
- 조해나: Evaluation
- 최우석: Binary classification, Trainer, Dataloader

References

- [1] Paul Ekman and Wallace V. Friesen. *Facial Action Coding System: A Technique for the Measurement of Facial Movement*. Consulting Psychologists Press, Palo Alto, CA, 1978.
- [2] Yingli Tian, Takeo Kanade, and Jeffrey F. Cohn. Recognizing action units for facial expression analysis. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 23(2):97–115, 2001.
- [3] Christian G. Kohler, Travis Turner, Neal M. Stolar, Warren B. Bilker, Colleen M. Brensinger, Raquel E. Gur, and Ruben C. Gur. Differences in facial expressions of four universal emotions. *Psychiatry Research*, 128(3):235–244, 2004.
- [4] Michel F. Valstar. *Timing is Everything: A Spatio-temporal Approach to Facial Action Analysis*. PhD thesis, Imperial College London, 2008.
- [5] Norhaida Hussain, Hamimah Ujir, Irwandi Hipiny, and Jacey-Lynn Minoi. 3d facial action units recognition for emotional expression. In *International Conference on Computer and Communication Engineering*, 2017.
- [6] Tadas Baltrušaitis, Amir Zadeh, Yao Chong Lim, and Louis-Philippe Morency. Openface 2.0: Facial behavior analysis toolkit. In *IEEE International Conference on Automatic Face and Gesture Recognition*, 2018.
- [7] Devvrat Mathur. Micro expression dataset for lie detection. <https://www.kaggle.com/datasets/devvratmathur/micro-expression-dataset-for-lie-detection>, 2023. Accessed: 2025-06-21.
- [8] Gargi Joshi, Vaibhav Tasgaonkar, Aditya Deshpande, Aditya Desai, Bhavya Shah, Akshay Kushawaha, Aadith Sukumar, Kermi Kotecha, Saumit Kunder, Yoginii Waykole, Harsh Maheshwari, Abhijit Das, Shubhashi Gupta, Akanksha Subudhi, Priyanka Jain, N. K. Jain, Rahee Walambe, and Ketan Kotecha. Multimodal machine learning for deception detection using real-world primary data. *Scientific Reports*, 15(1):1–15, 2025.
- [9] Viresh Gupta, Mohit Agarwal, Manik Arora, Tanmoy Chakraborty, Richa Singh, and Mayank Vatsa. Bag-of-lies: A multimodal dataset for deception detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, pages 1–8, 2019.
- [10] Krystian Radlak, Maciej Bozek, and Bogdan Smolka. Silesian deception database: Presentation and analysis. In *Proceedings of the ACM Workshop on Multimodal Deception Detection*. Association for Computing Machinery, 2015.
- [11] Verónica Pérez-Rosas, Mohamed Abouelenen, Rada Mihalcea, and Mihai Burzo. Deception detection using real-life trial data. In *Proceedings of the 2015 ACM on International Conference on Multimodal Interaction (ICMI '15)*, pages 59–66, New York, NY, USA, 2015. Association for Computing Machinery.
- [12] Rahayu Dwi Yeni, Chastine Fatichah, and Anny Yuniarti. Lies uncovered: Comparing the performance of deep learning techniques in video-based deception detection. In *Proceedings of the 2024 2nd International Conference on Communications, Computing and Artificial Intelligence*, pages 23–27. Association for Computing Machinery, 2024.
- [13] Camillo Lugaresi, Jiuqiang Tang, Hadon Nash, Chris McClanahan, Esha Ubowa, Michael Hays, Fan Zhang, Chuo-Ling Chang, Ming Guang Yong, Juhyun Lee, Wan-Teh Chang, Wei Hua, Manfred Georg, and Matthias Grundmann. Mediapipe: A framework for building perception pipelines. *arXiv preprint arXiv:1906.08172*, 2019.
- [14] Sauradip Nag, Ayan Kumar Bhunia, Aishik Konwer, and Partha Pratim Roy. Facial micro-expression spotting and recognition using time contrasted feature with visual memory. In *arXiv preprint*, 2019.
- [15] Di Chang, Yufeng Yin, Zongjian Li, Minh Tran, and Mohammad Soleymani. Libreface: An open-source toolkit for deep facial expression analysis. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, January 2024. To appear.
- [16] Linquan Wu, Wenhao Duan, and Tianxiang Jiang. A novel approach for micro-expression recognition incorporating vertical attention and position localization. <https://openreview.net/forum?id=mHYkcQzdae>, 2024. Submitted to ICLR 2024.